

Título del Informe

Mariano Fernández

May 14, 2026

Abstract

Contents

1	Exploración y Limpieza de Datos	2
1.1	Estudio de calidad de datos	2
1.1.1	Datos faltantes por columna	2
1.1.2	Cantidad de artículos por medio de prensa	2
1.2	Publicaciones en el tiempo	3
1.3	Normalización de texto	3
1.4	Elección de campos de texto	4
1.5	Pistas del medio de prensa en el texto	5
1.6	Restricción de los datos	6
2	Conteo de Palabras y Visualizaciones	7
2.1	Palabras más frecuentes	7
2.2	Medios con mayor cantidad de palabras	7
2.3	Menciones entre medios	7
2.4	Posibles preguntas	7

1 Exploración y Limpieza de Datos

1.1 Estudio de calidad de datos

1.1.1 Datos faltantes por columna

La figura 1 muestra la cantidad de valores nulos por columna, se ve un porcentaje muy alto para los campos de autor ($\sim 37.7\%$) y sección ($\sim 33.9\%$) por que se pierde una parte importante del dataset al momento de sacar conclusiones de estos campos. También hay un $\sim 3.9\%$ de artículos sin cuerpo y un $\sim 0.47\%$ sin medio de publicación, los dos campos principales para este estudio.




Figure 1: Cantidad de valores nulos por columna

1.1.2 Cantidad de artículos por medio de prensa

La distribución de cantidad de artículos por medio de prensa se muestra en la figura 2, se ve que un gran porcentaje de los artículos se concentran en pocos medios, este desbalance va a ser necesario considerarlo en una futura tarea de clasificación.

Figure 2: Cantidad de artículos por medio de prensa

Los cinco medios de prensa con con mayor cantidad de artículos son:

- Reuters
- The New York Times
- CNBC
- The Hill
- People

El resto del análisis se hace únicamente sobre estos medios.

1.2 Publicaciones en el tiempo

En la figura 3 se grafica la cantidad de publicaciones en el tiempo con una agrupando por mes, se ve un nivel mayormente estable con algunos períodos a destacar:

- Mediados de 2018 -> Comienzo de 2019: Reuters disminuyó mucho la cantidad de publicaciones
- Comienzos de 2019 en adelante: "CNBC" aumentó considerablemente la cantidad de publicaciones.
- Comienzos de 2020 en adelante: La cantidad de artículos publicados por "Reuters" creció mucho en un tiempo corto y acentúa la diferencia con los otros medios.
- Comienzos de 2020 en adelante: No hay nuevas publicaciones de "People".




Figure 3: Cantidad de publicaciones en el tiempo

1.3 Normalización de texto

Como paso previo al conteo de palabras se realiza una normalización del texto, las transformaciones aplicadas son las siguientes:

- Eliminar primeras palabras hasta el primer salto de línea.
- Convertir texto a minúsculas.
- Eliminar símbolos
 - Definidos previamente: "[, "\n", ",", ":", "?"

- Se agregan:
`"(", ")", "!", ".", ",", "\"", "'",
"‘", "/", ":", "]", "-", "#", ";", "x0", "\xa0", "\x7f"`
- El método de agregar símbolos a la normalización se podría mejorar ya que fue muy manual, para varios artículos muestreados aleatoriamente se imprimieron todas las palabras que tuvieran símbolos no alfanuméricos y se seleccionaron los relevantes. Una forma de mejorar esto podría ser usar una expresión regular para eliminar cualquier símbolo que no sea alfanumérico, con el riesgo de eliminar símbolos que puedan ser relevantes.
- Llenar nulos con un string vacío.

Algunos ejemplos del texto antes y después de la normalización se muestran en la tabla 1.

Title	Clean Title	Article	Clean Article
'Sonic the Hedgehog' faces video game adaptation box office curse	sonic the hedgehog faces video game adaptation box office curse	Hollywood has long tried to capitalize on the financial success and cultural relevance of video game	hollywood has long tried to capitalize on the financial success and cultural relevance of video game
Norway sets world record with electric cars sold last year TheHill	norway sets world record with electric cars sold last year thehill	Norway set a new world record last year after nearly a third of all its new car sales were electric,	norway set a new world record last year after nearly a third of all its new car sales were electric
BRIEF-FS Bancorp Inc announces commencement of public offering of common stock	brief fs bancorp inc announces commencement of public offering of common stock	Sept 5 (Reuters) - Fs Bancorp Inc * FS Bancorp Inc announces commencement of public offering of comm	sept 5 reuters fs bancorp inc * fs bancorp inc announces commencement of public offering of comm
Pawnee Nation Sues Oklahoma Oil Companies in Tribal Court Over Earthquake Damage	pawnee nation sues oklahoma oil companies in tribal court over earthquake damage	OKLAHOMA CITY — A Native American tribe here has filed a lawsuit in its own tribal court system accu	oklahoma city — a native american tribe here has filed a lawsuit in its own tribal court system accu
Turkey says agreed with Russia on details of Idlib ceasefire: Anadolu	turkey says agreed with russia on details of idlib ceasefire anadolu	ANKARA (Reuters) - Turkish and Russian officials have agreed on the details of a ceasefire in northw	ankara reuters turkish and russian officials have agreed on the details of a ceasefire in northw

Table 1: Ejemplos de texto antes y después de la normalización

1.4 Elección de campos de texto

En principio ambos el título y el cuerpo del artículo pueden contener información relevante a usar en una futura tarea de clasificación, pero esto va a depender del estudio que se realice. Por ejemplo si se combinan ambos en un campo solo para realizar tareas como conteo de palabras el título no va a agregar mucha información porque va a ser un porcentaje muy chico del total. Pero por otro lado parece razonable pensar que diferentes medios tengan "tipos" de títulos diferentes,

por lo dependiendo del modelo podría ser información útil a agregar. Para este caso se decide usar solo el cuerpo del artículo para el análisis de palabras por simplicidad.

1.5 Pistas del medio de prensa en el texto

Para estudiar si hay información que identifique muy fácilmente el medio de publicación de un artículo lo primero fue tomar muestras random de algunos artículos para cada medio y visualizar el comienzo y final del texto. Con unos pocos ejemplos ya se pueden sacar varias conclusiones:

1. Todos los artículos de *The Hill* terminan de la misma forma. Ejemplo:

```
...view the discussion thread the hill 1625 k street nw suite 900 ...  
capitol hill publishing corp a subsidiary of news communications inc
```

2. La mayoría de los artículos de *Reuters* terminan de la misma forma listando las personas que contribuyeron. Ejemplo:

```
...reporting by kylie maclellan writing by elizabeth piper editing  
by paul sandle
```

3. Todos los artículos de *Reuters* parecen comenzar con el patrón <lugar> y/o <fecha> - reuters. Ejemplos:

(a) may 10 reuters...

(b) kuala lumpur march 13 reuters...

(c) london reuters...

4. Parece haber un error en la data: varios artículos etiquetados como *CNBC* tienen el mismo comienzo y final que se ve en los artículos de *Reuters*. Ejemplos:

(a) bucharest aug 13 reuters ... reporting by radu marinas and alicja ptak
editing by alexandra hudson

(b) hong kong july 15 reuters ... reporting by julie zhu in hong kong writing
by jennifer hughes editing by jane merriman

Para verificar que no hubieran urls que identifiquen el medio en el texto se utilizó la siguiente expresión regular `r'(?:(https?://|www\.)([^\s]+)'` aplicada al cuerpo del texto sin normalizar, luego se agrupó por dominio para visualizar cuales aparecían en más de un 1% de los artículos por medio, no se encontraron resultados destacables.

Similarmente, para el caso de emails se utilizó una expresión regular para encontrar emails y tags que identifiquen el medio, en este caso se aplicó la expresión `r'\S*@[a-zA-Z0-9.-]+\S*'` sobre el cuerpo del artículo normalizado. A destacar:

- @cnbc aparece en 2.36% de los artículos del medio.
- @thehill aparece en 1.83% de los artículos del medio.
- @nytimes (7.68%) y @nytopinion (3.20%)

Medio de prensa: El caso más relevantes son las menciones del mismo medio, un gran porcentaje de los artículos menciona al medio en el cuerpo, el detalle se muestra en la tabla 2, el caso de Reuters y The Hill se explica por el uso de plantillas ya detectadas.

Table 2: Menciones del medio de prensa en el cuerpo del artículo

Medio de Prensa	"Pistas" (% de artículos con al menos una mención)
CNBC	cnbc (33.89%), madcap@cnbc (2.21%)
People	people (66.62%), peopletv (2.23%), peoplestyle (1.70%)
Reuters	reuters (88.58%)
The Hill	the hill (99.40%), @thehill (1.02%)
The New York Times	the new york times (16.97%)

A partir de estos resultados la primera decisión a tomar es que hacer con los artículos de CNBC que parecen tener un error de anotación, ya que tienen el mismo patrón que los artículos de Reuters. Cambiar el medio de publicación a Reuters puede ser una opción pero introduce un riesgo grande de que no todos los artículos afectados sean de Reuters, si se estuviera trabajando con un conjuntos de datos más pequeño tendría sentido dedicar más tiempo a este análisis pero para este caso "Reuters" ya es el medio con más artículos por lo que se decide eliminar los artículos de CNBC que tengan el patrón de Reuters, este es el camino más seguro para evitar introducir un sesgo incorrecto.

Luego la decisión de eliminar estos patrones depende de cual es el objetivo final, si a partir de estos datos se va a intentar obtener un modelo de clasificación es necesario que los datos de entrenamiento tengan una distrubución lo más cerca posible a la distribución real donde se va a aplicar el modelo. No eliminar estos patrones simplifican mucho el problema pero asumen que esto no va a cambiar, lo que haría que el modelo tenga una capacidad de generalización muy baja, por ejemplo si un día reuters cambia el modelo perdería la capacidad de clasificar correctamente. Para este estudio se decide eliminar los patrones más evidentes, en particular se usan las siguientes expresiones regulares para eliminar esa sección del texto.

- `r'(view the discussion thread )?the hill 1625 k street nw suite 900.*'`
- `r'reporting by.*'`
- `r'^[a-z\s\d]{5,30}reuters'`
- `r'@cnbc'`
- `r'@thehill'`
- `r'@nyt\w*'`

1.6 Restricción de los datos

Dado el análisis temporal realizado en las sección 1.2 filtraría los datos posteriores a 2020, ya que dejan de haber publicaciones de "People". Graficando la cantidad de publicaciones para los diferentes meses del año no hay una diferencia clara para ninguno de los medios, si se diera

el caso que no hayan o hayan menos publicaciones para un medio en algún momento del año podría haber sido útil filtrar ese período.

Si hay secciones temáticas que publican solo algunos medios y otros no se repite una discusión similar a que patrones de los datos es necesario eliminar o reducir su impacto, si no se restringe a temáticas sobre las que escriben todos los medios el modelo podría aprender un sesgo de que cierta temática está asociada a cierto medio pero si eso cambia en el futuro o los datos de entrenamiento no estaban completos la precisión del modelo va a ser baja.

2 Conteo de Palabras y Visualizaciones

2.1 Palabras más frecuentes

La figura 4 es un mapa de calor de las 5 palabras más frecuentes para cada medio de prensa (hay mucho solapamiento entre los medios), en general todas son artículos que no aportan información relevante, por ejemplo "the", "to", "of", "a", "and", etc. Y son frecuentes en todos los medios, con algunas diferencias.

En la figura 5 se vuelve a realizar el conteo de palabras pero eliminando las "stopwords" del idioma inglés con la librería nltk, esto mejora mucho la visualización y ya se pueden tomar conclusiones interesantes, por ejemplo "The Hill" tiene muchas más menciones de "Trump" que los otros medios.

Algo se puede ver en la figura 5 pero sería interesante una visualización que muestre las palabras que son muy frecuentes en un medio pero no en los otros.

2.2 Medios con mayor cantidad de palabras

En la figura 6 se muestra la cantidad total de palabras publicadas por medio de prensa, un punto muy interesante es que "Reuters" tiene cantidad similar "The New York Times" que tiene mucho menos artículos publicados. Esto último se puede visualizar mejor en la figura 7 donde se normaliza la cantidad de palabras por la cantidad de artículos publicados por medio, esto nos da una idea del tamaño promedio de los artículos por medio.

2.3 Menciones entre medios

Visualizando las menciones entre medios de prensa se ve un problema importante, la palabra "People" es muy común por lo que en las figuras 8 y 9 se ve que "People" tiene muchas menciones de todos los medios. Una posible forma de mitigar este problema es hacer el matching antes de pasar el texto a minúsculas, ya que los casos de "People" con mayúscula que no refieran al medio de prensa deberían ser solo al comienzo de una oración, y esos también se podrían filtrar con expresiones regulares.

2.4 Posibles preguntas

Algunas preguntas interesantes para seguir explorando los datos podrían ser:

- ¿Hay diferencias en la "complejidad" de los artículos entre medios de prensa?

Se podría medir la cantidad de palabras por artículo, o el tipo de palabras utilizadas.




Figure 4: Palabras más frecuentes por medio de prensa

- ¿Los medios tienen un sentimiento predominante asociado a noticias de ciertas temáticas?
Una forma sería contar la cantidad de palabras positivas / negativas por tema y medio de prensa, aunque esto es un método muy simple, para llegar a buenos resultados lo ideal sería un modelo de análisis de sentimiento.

- ¿Es viable detectar el medio de prensa de un artículo a partir de la frecuencia de las palabras usadas?

Una forma sería definir como features a la frecuencia de las palabras usadas y tomar eso como entrada del modelo.




Figure 5: Palabras más frecuentes (sin stopwords)




Figure 6: Cantidad de palabras por medio de prensa




Figure 7: Cantidad de palabras por medio de prensa normalizado por cantidad de artículos




Figure 8: Matriz de menciones entre medios de prensa




Figure 9: Grafo de menciones entre medios de prensa